Anexo C Pruebas preliminares

C.1 Definición estricta de no vocalizado

Tabla C1

Comparación de cantidad de fragmentos no vocalizados (solo fonemas de amplio espectro contra fonemas de amplio espectro y ruido)

Definición	Condición	Fragmentos	Duración total
Estricta (speaker_25)	Limpia	45	8.45 s
Estricta (speaker_25)	Con ruido	50	10.06 s
Final: no vocalizado + ruido de fondo (speaker_13)	Limpia	153	43.17 s
Final: no vocalizado + ruido de fondo (speaker_13)	Con ruido	112	47.06 s

Comparación con la definición estricta. En pruebas preliminares se evaluó restringir el entrenamiento a los tramos sin voz cuya energía supera el umbral de silencio. Para la toma speaker_25, esta definición produjo 45 fragmentos (8.45 s) en la condición limpia y 50 (10.06 s) en la condición con ruido, con duración media de 0.19 y 0.20 s. Con la definición adoptada, que incluye también el ruido de fondo, la toma speaker_13 conserva 43.17 s y 47.06 s (tabla anterior). Al ser tomas distintas, la comparación es indicativa, ya que todos los audios siguen el mismo guión, y su duración solo varía entre 65 segundos y 87 segundos aproximadamente. En esas pruebas se observó un desempeño inferior del modelo con solo los fonemas de amplio espectro, sin incluir el ruido, lo cual se atribuye principalmente a la escasez de datos.

C.2 Función de pérdida (comparación preliminar)

La pérdida se eligió con una versión preliminar del sistema. Cada configuración se entrenó 15 épocas, se evaluó con distancia euclidiana y se hizo una sola ejecución (semilla 42). La comparación se realizó con los valores de referencia de cada pérdida: CosFace con s = 64 y m = 0.35 (Wang et al., 2018) y ArcFace con s = 64 y m = 28.6° (Deng et al., 2019), sin ajuste individual. Estos valores no corresponden a los del modelo final (s = 30 y m = 0.2, sección 2.4.3), que se adoptaron después porque con los de referencia el entrenamiento tardaba demasiado en converger. Por tanto, esta comparación respalda la elección de CosFace como pérdida, pero no los valores finales de m y s.

Tabla C2

Comparación de funciones de pérdida (versión preliminar, 15 épocas)

Pérdida	EER ventana (%)	EER audio (%)	Umbral	Error de localización, base (s)
Tripletas(Hard)	20.7	20.6	0.0023	5.8
ArcFace	25.7	31.0	0.221	13.5
CosFace	23.3	33.5	0.890	8.7

Las tripletas obtuvieron el menor EER, pero con un umbral de $\approx 10^{-3}$ frente a ≈ 0.9 en CosFace. Con distancias tan pequeñas el EER puede seguir siendo bajo, porque solo depende del orden de las puntuaciones, pero la distancia deja de ser interpretable y el umbral queda expuesto al ruido numérico. Entre ArcFace y CosFace los resultados van en ambos sentidos: CosFace fue mejor por ventana y en localización, y ArcFace fue mejor por audio. Se adoptó CosFace por su desempeño por ventana y en localización.

Con la versión final del sistema se probaron tripletas con minería hard y con minería semihard. Con minería hard la pérdida se mantuvo en torno a 0.2 desde la primera época, que es el valor del margen, y con minería semihard cerca de 0.1 desde las primeras épocas. En ambos casos la pérdida dejó de descender, lo que indica colapso de los embeddings (Schroff et al., 2015; Hermans et al., 2017), por lo que no se continuó con esa opción. La Tabla C.3 compara la estructura del espacio de embeddings de CosFace y de las tripletas semihard.

Tabla C3

Estructura del espacio de embeddings, versión final (distancia euclidiana; referencia isotrópica de la desviación por dimensión: 0.125)

Pérdida	Conjunto	Desv. por dimensión	Distancia intra	Distancia inter	Razón inter/intra
CosFace	Validación	0.1225	0.647	1.418	2.19
CosFace	No vistos	0.0074	0.079	0.082	1.05
Tripletas semihard	Validación	0.1165	0.771	1.200	1.56
Tripletas semihard	No vistos	0.0649	0.496	0.530	1.07

En validación CosFace logra mayor separación (razón de 2.19 frente a 1.56). La dispersión de las tripletas semihard (0.1165) es cercana a la isotrópica, de modo que se observa

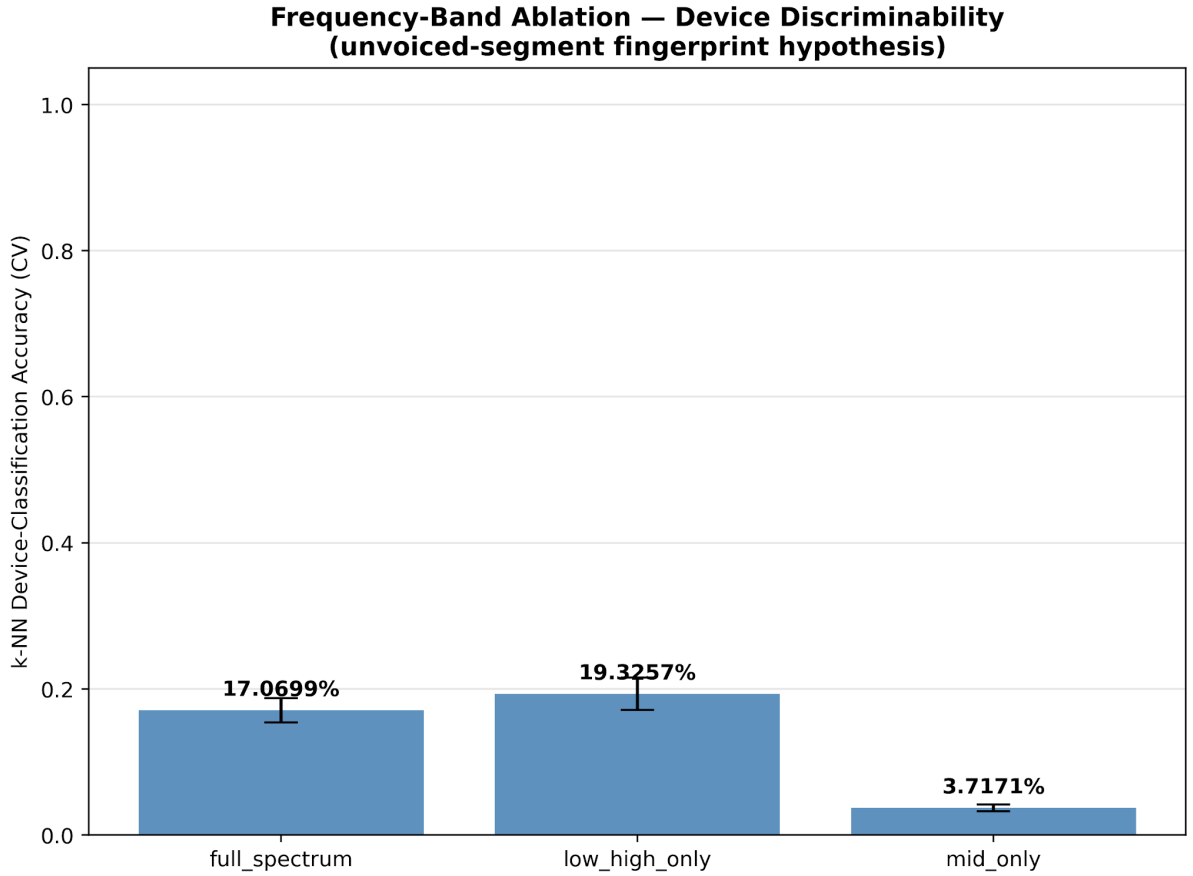
estancamiento de la pérdida pero no colapso con esta geometría. En dispositivos no vistos ambas pérdidas quedan con razón cercana a 1, es decir, casi sin separación.

C.3 Ablación por bandas de frecuencia.

Se midió la separabilidad de dispositivos con k-NN (k = 5, validación cruzada de 5 pliegues agrupada por audio) sobre el espectrograma normalizado aplanado, con tres variantes: espectro completo, solo extremos (se anula la banda de 100 Hz a 3 kHz) y solo banda media. Las exactitudes fueron 17.07 ± 1.67 %, 19.33 ± 2.22 % y 3.72 ± 0.49 %, respectivamente (63 840 ventanas; azar = 5 %). Anular la banda media no redujo la exactitud, mientras que conservar solo esa banda la dejó por debajo del azar. Esto es consistente con la hipótesis de Calderón Ardila (2023) , según la cual la huella del micrófono se concentra en los extremos del espectro. Al ser un k-NN sobre vectores de alta dimensión, los niveles absolutos son bajos y solo la comparación relativa es informativa. La diferencia entre espectro completo y extremos está dentro de la dispersión entre pliegues.

Figura C1

Ablación por bandas de frecuencia



C.4 Verificación de alineación entre dispositivos

Para reutilizar los fragmentos no vocalizados de una toma en todos los dispositivos (sección 2.3.1), se estimó por correlación cruzada el desfase entre las grabaciones de cada toma, con el Huawei Nova 9 como referencia (1140 pares toma-dispositivo). El desfase máximo fue de 1632 muestras (37 ms), en el iPhone 12 mini, y 104 pares superan las 441 muestras (10 ms) que absorbe el margen de guarda. Los mayores desfases medios corresponden al iPhone 12 mini (−792 muestras), el iPhone 13 (−549) y el iPhone XS Max (−361).

Como cota superior de la contaminación por habla en los fragmentos, se estimó la fracción afectada por el desfase respecto al dispositivo de referencia de cada toma. Es nula en 16 de los 20 dispositivos. En los demás es, en promedio, de 3.7 % (máximo 13.0 %) en el iPhone 12 mini, 1.8 % (máximo 7.1 %) en el iPhone 13, 0.5 % (máximo 3.1 %) en el iPhone XS Max y menor de 0.2 % en el ROG Phone 5. Se asumió un desfase constante por toma. La contaminación es pequeña en general en los tres iPhone (sección 2.3.1) .