## Anexo E. Evaluación de la separabilidad del embedding con k-NN y curva de pérdida del modelo definitivo

### E.1 Propósito

Este anexo respalda la sección 2.5.2. Reúne tres evidencias sobre el modelo definitivo:

- la curva de pérdida y el historial de la tasa de aprendizaje durante el entrenamiento;
- la exactitud de un clasificador k-NN sobre los embeddings, en entrenamiento y en prueba;
- la matriz de confusión por dispositivo.

El k-NN es un diagnóstico de separabilidad entre los 20 dispositivos vistos. No sustituye la evaluación por EER de la detección de empalmes, que es la métrica del plan (capítulo de Resultados).

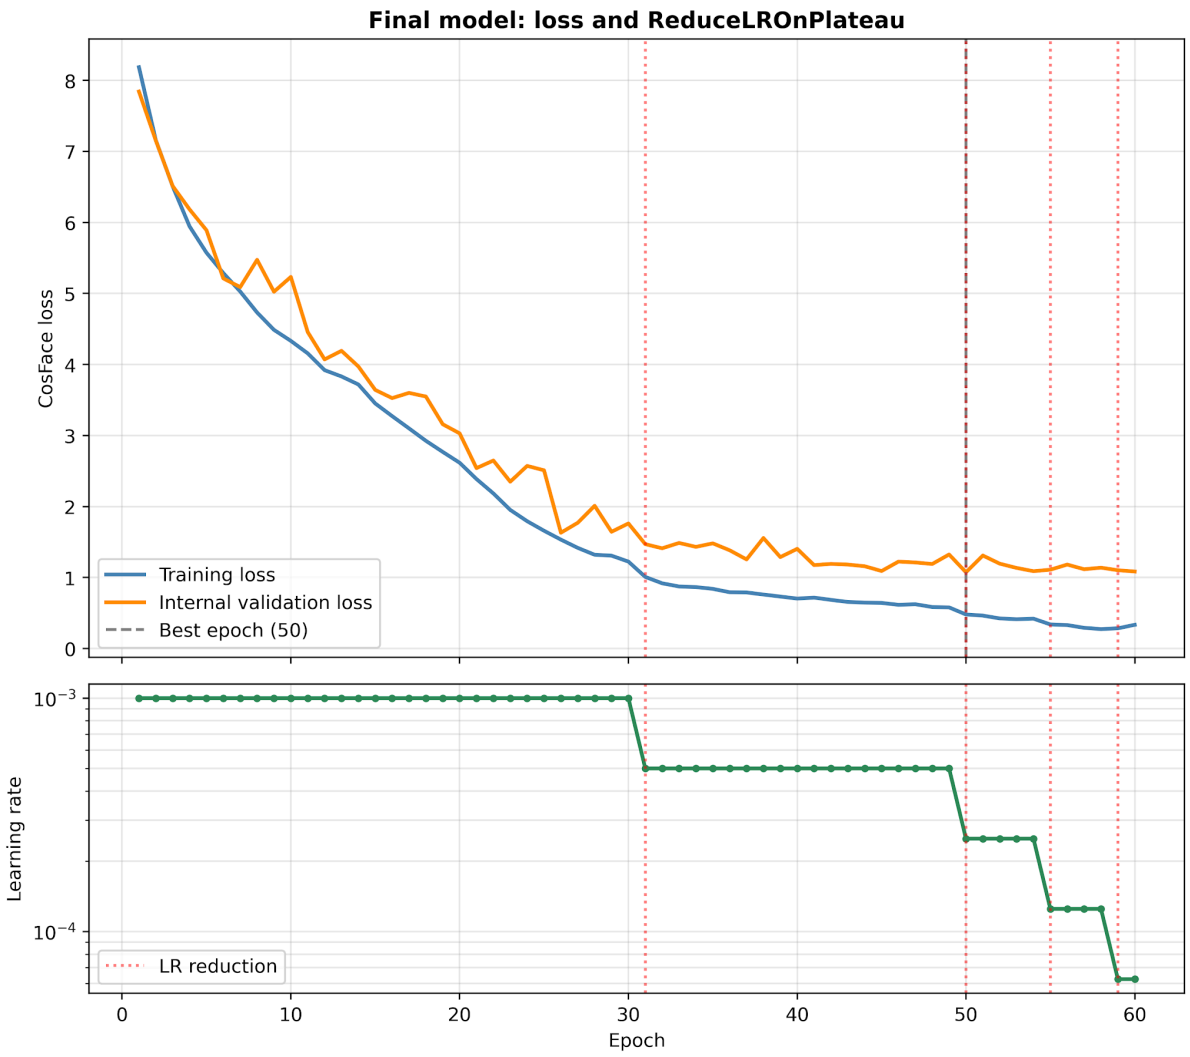
### E.2 Curva de pérdida del entrenamiento

La Figura E.1 muestra la pérdida CosFace por época del modelo definitivo, sobre las ventanas de entrenamiento (fragmentos no vocalizados concatenados) y sobre el control interno (15 % de los audios de entrenamiento, audio completo). El panel inferior muestra la tasa de aprendizaje.

El entrenamiento completó las 60 épocas posibles. La detención temprana no se activó, porque la paciencia es de 15 épocas y la mejor época fue la 50, de modo que solo transcurrieron 10 épocas sin mejora. Se restauraron los pesos de la época 50, con pérdida de control de 1.0739 y pérdida de entrenamiento de 0.4797. En la última época las pérdidas fueron 0.3340 (entrenamiento) y 1.0843 (control). La tasa de aprendizaje se redujo cuatro veces mediante la reducción adaptativa (ReduceLROnPlateau, de PyTorch), en las épocas 31, 50, 55 y 59, de $1.0\times10^{-3}$ a $6.3\times10^{-5}$.

**Figura E1**

*Pérdida CosFace de entrenamiento y de control interno por época (panel superior) e historial de la tasa de aprendizaje (panel inferior). La línea gris discontinua marca la mejor época (50) y las líneas rojas punteadas, las épocas en que la tasa de aprendizaje ya había sido reducida.*




**Interpretación de las curvas.**

1. La pérdida de entrenamiento se promedia durante la época con dropout activo y muestreo balanceado de 8 ventanas por dispositivo. La de control se calcula en modo de evaluación, sin dropout.
2. Las dos curvas se miden sobre dominios distintos: contenido no vocalizado concatenado en entrenamiento y audio completo con habla en el control.
3. La pérdida de control (loss) es la que gobierna la reducción de la tasa de aprendizaje y la selección del punto de control final.

**Observaciones.** Ambas pérdidas descienden de forma sostenida durante las primeras 30 épocas, de unos 8 a aproximadamente 1.7 en el control, con oscilaciones más marcadas en el control. La primera reducción de la tasa de aprendizaje (época 31) coincide con una caída visible de la pérdida de control, de aproximadamente 1.7 a 1.5. Desde la época 40 aproximadamente, el control se estabiliza entre 1.1 y 1.3. Las reducciones siguientes aportan

mejoras marginales: la mejor época coincide con la primera tras la segunda reducción, y las épocas 51 a 60 no la superan.

Mientras tanto, la pérdida de entrenamiento sigue bajando, de modo que la brecha entre ambas crece, de unos 0.5 hacia la época 30 a unos 0.75 al final. Como el entrenamiento terminó por el límite de épocas y no por la detención temprana, no puede afirmarse que se alcanzó convergencia estricta, aunque la estabilización del control indica que prolongarlo aportaría poco.

**E.3 Exactitud del k-NN: entrenamiento frente a prueba**

**Protocolo.** Se usó un k-NN con k = 5 y distancia euclidiana, sobre embeddings de ventanas de 1 s sin traslape extraídas del audio completo. Así los embeddings de referencia, los de entrenamiento y los de prueba comparten el dominio, igual que en la calibración y la evaluación.

- **Referencia:** ventanas de los 840 audios de entrenamiento. Esto incluye los 126 audios del control interno, que no intervinieron en el ajuste de los pesos.
- **Prueba:** ventanas de los 200 audios de prueba, nunca vistos.
- **Exactitud en entrenamiento:** validación cruzada estratificada de 5 pliegues dentro del conjunto de referencia, porque predecir sobre los mismos puntos daría una exactitud artificial cercana al 100 %.
- **Intervalo de confianza de prueba:** bootstrap percentil del 95 % con 1000 remuestreos, remuestreando audios completos y no ventanas.

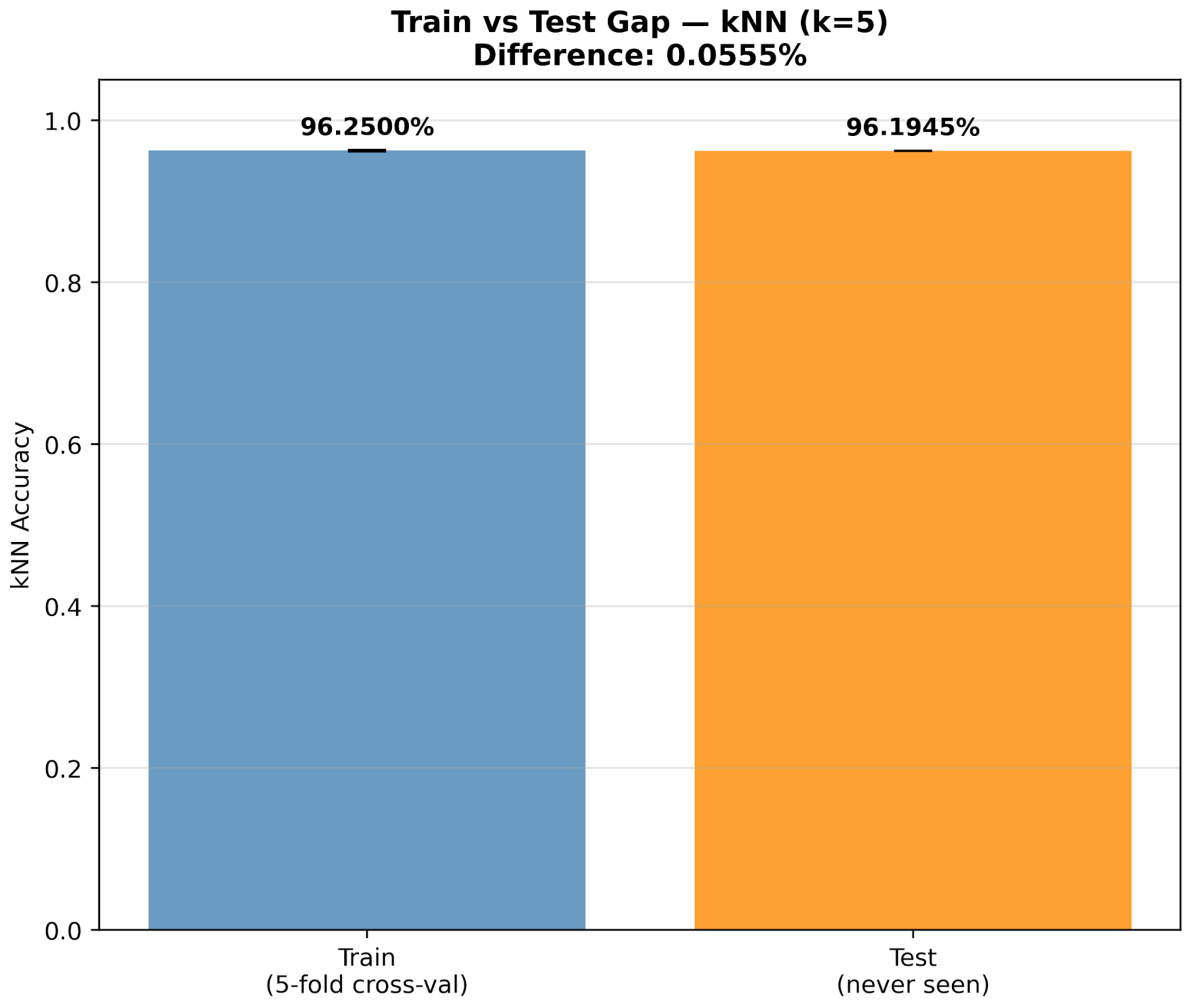
**Tabla E1**

*Exactitud del k-NN (k = 5) sobre los embeddings del modelo definitivo*

| Conjunto | Exactitud (%) | Observación |
|---|---|---|
| Entrenamiento (CV de 5 pliegues) | 96.25 ± 0.08 | Desviación estándar entre pliegues |
| Prueba (nunca visto) | 96.19 [IC 95 %: 95.02, 97.24] | IC bootstrap por audio (n = 200 audios) |

**Figura E2**

*Exactitud del k-NN en entrenamiento (validación cruzada de 5 pliegues) y en prueba.*




**Interpretación.** La exactitud en prueba es de 96.19 %, unos 91 puntos porcentuales por encima del azar (5 %), de modo que el embedding separa con claridad los 20 dispositivos en audios que el modelo no vio. La diferencia con entrenamiento es de solo 0.06 puntos porcentuales y el valor de entrenamiento cae dentro del intervalo de confianza de prueba. A nivel de separabilidad entre dispositivos vistos no hay indicio de sobreajuste.

**E.4 Matriz de confusión por dispositivo**

La Figura E.3 muestra la matriz de confusión del k-NN sobre prueba, normalizada por filas, de modo que la diagonal es la sensibilidad (recall) de cada dispositivo. La Figura E.4 presenta la equivalente para entrenamiento (CV de 5 pliegues).

**Figura E3**

*Matriz de confusión del k-NN, conjunto de prueba.*

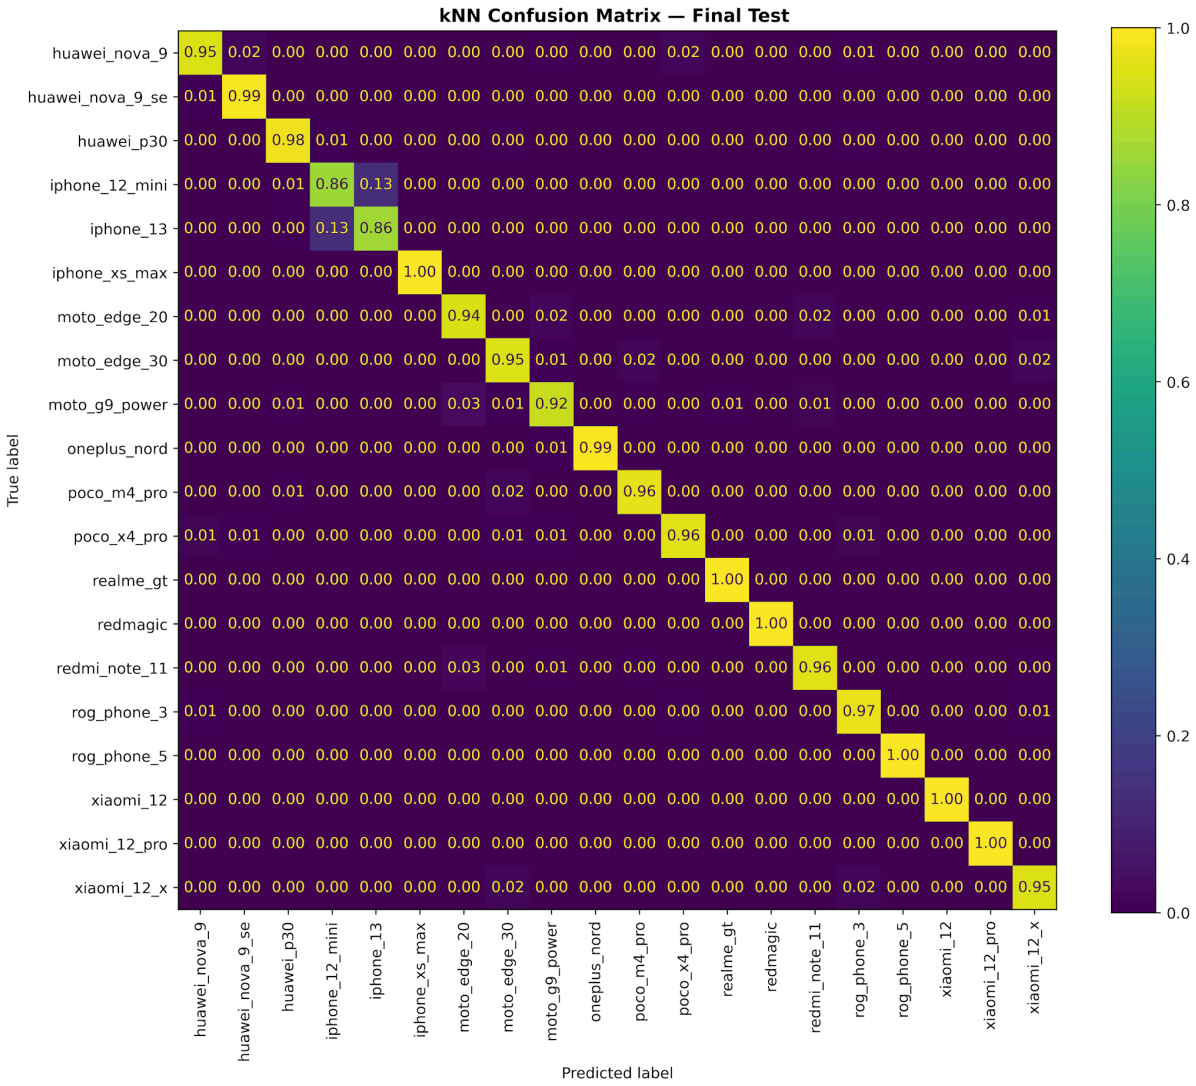
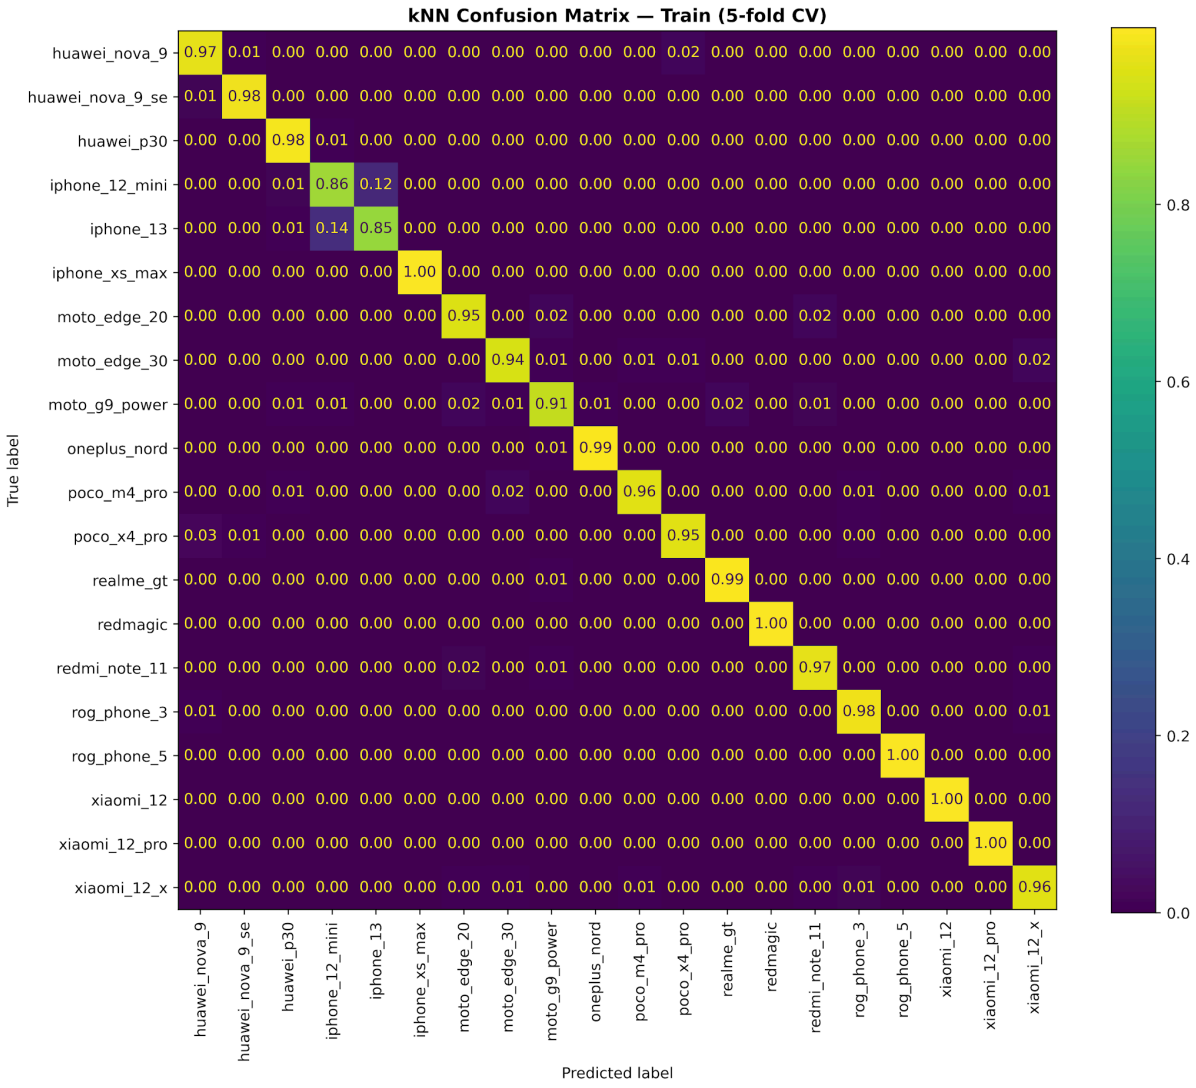

kNN Confusion Matrix — Final Test
True label
Predicted label
huawei_nova_9
huawei_nova_9_se
huawei_p30
iphone_12_mini
iphone_13
iphone_xs_max
moto_edge_20
moto_edge_30
moto_g9_power
oneplus_nord
poco_m4_pro
poco_x4_pro
realme_gt
redmagic
redmi_note_11
rog_phone_3
rog_phone_5
xiaomi_12
xiaomi_12_pro
xiaomi_12_x
0.0
0.2
0.4
0.6
0.8
1.0

**Figura E4**

*Matriz de confusión del k-NN, entrenamiento (CV de 5 pliegues).*




Esta validación cruzada de 5 pliegues se aplica solo al clasificador k-NN sobre los embeddings del modelo definitivo, y es independiente de la validación cruzada de 3 pliegues empleada para verificar el esquema de entrenamiento (sección 2.5.1).

**Descripción (entrenamiento, Figura E.4).** La diagonal es alta en casi todos los dispositivos, con sensibilidades de 0.85 a 1.00. Los más separables (1.00) son iPhone XS Max, Redmagic, ROG Phone 5, Xiaomi 12 y Xiaomi 12 Pro. Los peores son el iPhone 13 (0.85) y el iPhone 12 mini (0.86), que se confunden principalmente entre sí (0.12 y 0.14), seguidos del Moto G9 Power (0.91), cuyos errores son pequeños y dispersos entre varios dispositivos. El resto de las confusiones no supera 0.03. La concentración del error en un par del mismo fabricante es plausible, pero el motivo (hardware de micrófono similar entre ambos modelos) es una hipótesis, cuya verificación, no entra dentro de los alcances de este proyecto.

**Dispositivos con comportamiento atípico.** Salvi et al. (2025) señalan que el Xiaomi 12 y el Xiaomi 12 Pro eliminan el contenido sobre 8 kHz y que el Moto G9 Power parece anular los tramos sin habla. La matriz no respalda que los Xiaomi sean los más confundidos: ambos se identifican perfectamente (1.00) y no se confunden entre sí. El Moto G9 Power sí está entre los menos separables (0.91), pero con errores dispersos, lo que no permite atribuirlo a ese comportamiento.

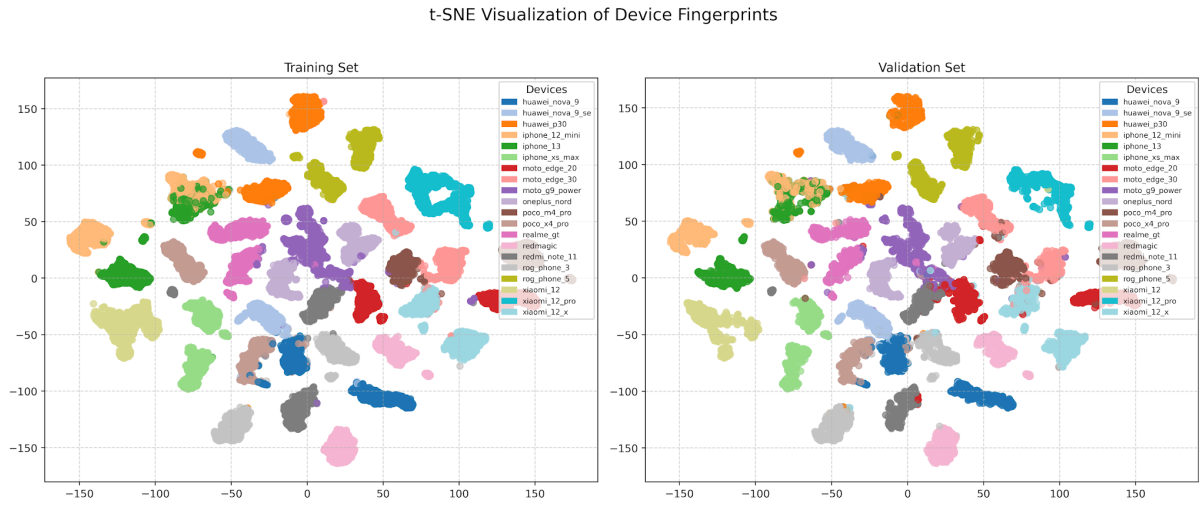
**Alcance.** Esta matriz mide la identificación de dispositivo entre los 20 vistos, no la detección de empalmes. Un par de dispositivos muy confundidos entre sí, como el iPhone 12 mini y el iPhone 13, es un par cuyo empalme sería probablemente más difícil de detectar.

**E.5 Visualización t-SNE de los embeddings**

Para complementar las métricas cuantitativas de las secciones anteriores, se proyectaron a dos dimensiones los embeddings de 64 dimensiones del modelo definitivo mediante t-SNE (perplejidad 50, 2000 iteraciones, inicialización por PCA, semilla 42). Se ajustó una única proyección conjunta para las ventanas de entrenamiento y las de prueba, de modo que ambos paneles comparten el mismo mapa. Las ventanas de entrenamiento provienen de los fragmentos no vocalizados concatenados y las de prueba, del audio completo; en ambos casos son ventanas de 1 s sin traslape. Cada punto es una ventana y su color indica el dispositivo (20 en total).

**Figura E5**

*Proyección t-SNE de los embeddings: entrenamiento (izquierda) y prueba (derecha).*




En ambos paneles se observan agrupaciones por dispositivo, con una estructura similar entre entrenamiento y prueba. Algunos dispositivos, como el iPhone 12 mini y el iPhone 13, aparecen mezclados en una misma región. Sin embargo, t-SNE reduce los embeddings de 64 a 2 dimensiones, conserva la vecindad local pero no las distancias globales ni el tamaño

relativo de los grupos, y su resultado depende de la perplejidad y de la inicialización. Por eso se presenta solo como apoyo visual, una impresión cualitativa de la separación. La evidencia de separabilidad son la exactitud del k-NN (96.19 %) y el EER por pares (≈ 3 %).