ANEXO A Parámetros de preprocesamiento, arquitectura y entrenamiento

Este anexo reúne los parámetros que se omitieron de las secciones 2.3 a la 2.5 para mantener la descripción general breve.

A.1 Ventaneo y frecuencia de muestreo

Tabla A1

Parámetros de ventaneo y frecuencia de muestreo

Parámetro	Valor
Frecuencia de muestreo	44.1 kHz
Duración de la ventana de análisis	1 s
Desplazamiento en entrenamiento y validación del entrenamiento	1 s (sin traslape)
Desplazamiento en calibración, inferencia y evaluación	0.25 s (75 % de traslape)

A.2 Extracción espectral

De cada ventana se calcula la transformada de Fourier de corto tiempo con ventana de Hann, 2048 muestras por trama y salto de 2048 muestras, es decir, sin solapamiento entre tramas. El espectrograma de potencia se convierte a decibelios (10·log10 con un piso numérico de 1e-10) y se estandariza con la media y la desviación estándar de cada ventana (z-score por ventana). El resultado es una matriz de 1025 bins de frecuencia por 22 tramas temporales por cada ventana de 1 s.

A.3 Detección de segmentos no vocalizados

Tabla A2

Parámetros de detección y segmentación de contenido no vocalizado

Parámetro	Valor
Estimador de tono	pYIN, rango de C2 a C6
Trama y salto de análisis	1024 y 128 muestras (escalados a la frecuencia de análisis)
Frecuencia de análisis del estimador	16 kHz (el audio se remuestrea solo para esta etapa)
Margen de guarda alrededor de cada trama vocalizada	0.01 s
Filtro de silencio digital	Se descartan tramas con RMS inferior a -80 dBFS

Regiones de ruido de fondo	Se conservan si no son vocalizadas ni silencio digital
Duración mínima de fragmento	0.0232 s
Unión de fragmentos cortos	No se unen: los fragmentos menores al mínimo se descartan
Concatenación	En orden temporal, por audio
Corte en ventanas	De 1 s sin solapamiento; el remanente incompleto se descarta

La duración mínima de fragmento es de 1025 muestras (≈ 23.2 ms a 44.1 kHz), el mínimo que exige la STFT: la librería usada (librosa) agrega a cada extremo de la señal una cantidad de muestras igual a la mitad de la longitud de la trama (1024 muestras), y para ello la señal necesita al menos 1025 muestras. Todas las tomas se grabaron con la misma señal de entrada en los veinte dispositivos, por lo que los tramos no vocalizados de una toma ocupan las mismas posiciones temporales en todos ellos. Por eso los fragmentos se calculan una sola vez por toma, con el primer dispositivo encontrado como referencia, y se reutilizan en los demás. Esto es válido porque las duraciones de los audios solo cambian entre tomas (por la voz grabada) y no entre dispositivos (Salvi et al., 2025); la alineación se verificó en el Anexo C.

A.4 Resumen de los fragmentos extraídos

La tabla muestra el resultado de la extracción para una toma representativa por condición (speaker_13.wav, toma de unos 87 s). Como los fragmentos se calculan una sola vez por toma, esta toma sirve de ejemplo para todos los dispositivos.

Tabla A3

Fragmentos no vocalizados extraídos en una toma representativa por condición

Condición	Fragmentos	Duración media ± desv. est. (s)	Mínimo (s)	Máximo (s)	Duración total no vocalizada (s)
Limpia	153	0.2822 ± 0.3220	0.0315	1.4805	43.1725
Con ruido	112	0.4202 ± 0.6448	0.0286	5.0930	47.0637

Los fragmentos son muy cortos: la duración media es de unas pocas décimas de segundo y casi todos duran menos de 1 s. Por esto se concatenan en lugar de ventanearse por separado, de modo que cada ventana de 1 s resulta de unir varios fragmentos y las uniones no coinciden con ninguna pausa real del audio. En la toma de ejemplo, el audio no vocalizado equivale a algo más de la mitad de la duración total en ambas condiciones (aproximadamente 50 % en la

limpia y 54 % en la ruidosa, sobre unos 87 s). La condición con ruido presenta menos fragmentos pero más largos y con mayor dispersión, y los audios presentan un fragmento inicial de 5.09 s de ruido o silencio,dependiendo de la condición (salvi et al., 2025). Tras la partición interna del 15 %, el ajuste del modelo definitivo emplea 29,971 ventanas de 1 s provenientes de 714 audios, con una media de 42.0 ± 6.7 ventanas por audio (mínimo 26, máximo 55). El conjunto de control interno, construido con audio completo y ventanas no solapadas de 1 s, aporta 9,568 ventanas de 126 audios (75.9 ± 7.2 por audio).

A.5 Arquitectura de la red

Tabla A4

Arquitectura de la red: capas, forma de salida y parámetros por bloque

Bloque	**Capas**	**Forma de salida**	**Parámetros**
Entrada	Espectrograma log-potencia normalizado	1 × 1025 × 22	n/a
1	Conv 3×3 (64 canales, relleno 1), BatchNorm, ReLU, MaxPool 2×2, Dropout2d (0.1)	64 × 513 × 11	768
2	Conv 3×3 (128 canales, relleno 1), BatchNorm, ReLU, MaxPool 2×2, Dropout2d (0.1)	128 × 257 × 6	74 112
3	Conv 3×3 (256 canales, relleno 1), BatchNorm, ReLU, Dropout2d (0.1), sin MaxPool	256 × 257 × 6	295 680
Cabeza 1	Promediado espacial global, Linear 1024, ReLU, Dropout (0.1), Linear 256, ReLU, Dropout (0.1), Linear 64	Vector de 256 a la entrada y de 64 a la salida	542 016
Salida	Normalización L2	64	0
Total			**912 576**

Los MaxPool usan redondeo hacia arriba , por eso en frecuencia, el tamaño pasa de 1025 a 513 en el primer bloque y a 257 en el segundo; en tiempo, de 22 a 11 y luego a 6. Los parámetros de cada bloque incluyen pesos y sesgos de la convolución más escala y desplazamiento de BatchNorm. Las estadísticas acumuladas de BatchNorm (media y varianza móviles) son buffers y no se cuentan como parámetros. Los pesos de las capas convolucionales y lineales se inicializan con el método de Kaiming. El costo computacional por ventana es de 894 966 912 MACs, estimado con THOP (1 MAC ≈ 2 FLOPs por convención).

Tabla A5

Detalle de las capas densas

Capa	Entradas	Salidas	Parámetros
Linear 1	256	1024	263 168
Linear 2	1024	256	262 400
Linear 3	256	64	16 448

Como el promediado espacial global colapsa las dimensiones de frecuencia y tiempo, la arquitectura admite espectrogramas de distinta duración sin modificar las capas densas. En este trabajo, sin embargo, todas las ventanas tienen 1 s y no se evaluó esa propiedad.

A.6 Hiperparámetros del entrenamiento

Tabla A6

Hiperparámetros usados en el entrenamiento

Parámetro	Valor
Función de pérdida	CosFace (margen 0.2, escala 30)
Optimizador	AdamW
Tasa de aprendizaje (pruebas con pérdida de tripletes)	0.001
Tasa de aprendizaje (CosFace)	0.01, sin decaimiento de pesos
Decaimiento de pesos (red)	1e-4
Recorte de gradiente (norma)	1.0
Tamaño de lote	128
Muestreo por lote	Balanceado por clase (MPerClassSampler, 8 muestras por clase)
Validación cruzada	3 pliegues estratificados por dispositivo y condición, 8 épocas por pliegue
Modelo definitivo	w
Partición interna para control	15 % de los audios de entrenamiento, estratificada
Reducción de tasa de aprendizaje	ReduceLROnPlateau (factor 0.5, paciencia 3, umbral relativo 1e-4, mínimo 1e-6)
Detención temprana	Paciencia 15, mejora mínima 1e-4
Semilla aleatoria	42

Los tiempos se midieron en una máquina virtual de Google Colab con CPU Intel Xeon a 2.0 GHz (4 hilos) y GPU NVIDIA Tesla T4. Se analizaron 30 audios del conjunto de prueba (duración media de 75 s), con 3 audios de calentamiento previos que no se cronometraron. Cada análisis incluye la extracción de ventanas con STFT y normalización, el paso de la red y el cálculo de las distancias consecutivas. El procesador se identificó con el comando lscpu. Los tiempos son una referencia, porque el entorno es compartido y puede variar entre sesiones.

Tabla A7

Tiempo de análisis por audio (media ± desv. est.)

Etapa	CPU (s)	GPU (s)
STFT y normalización	0.353 ± 0.036	0.352 ± 0.037
Paso de la red (forward)	5.330 ± 0.596	0.195 ± 0.018
Distancias consecutivas	0.00013 ± 0.00002	0.00012 ± 0.00002
Total por audio	5.683 ± 0.627	0.548 ± 0.055
ms por ventana (STFT / red)	1.19 / 17.97	1.19 / 0.66
Factor de tiempo real	0.076	0.007

A.7 Partición de los datos

Este anexo respalda la sección 2.2.2. Reúne los conteos por subconjunto, la verificación de consistencia entre dispositivos y los tamaños efectivos de las muestras de evaluación.

A.7.1 Conteo por dispositivo y condición

La partición se aplicó por separado a cada una de las 40 combinaciones dispositivo–condición, con 30 audios cada una. En el primer paso se separó el 30 % (9 audios), con lo que quedaron 21 para entrenamiento. En el segundo, ese remanente se dividió al 50 %. Como 9 es impar, la función de partición asigna el redondeo hacia arriba al subconjunto de prueba.

Tabla A8

Audios por subconjunto

Subconjunto	Audios por combinación	Total	Proporción
Entrenamiento	21	840	70.0 %

Validación	4	160	13.3 %
Prueba	5	200	16.7 %
Total	30	1200	100 %

Los conteos son idénticos para los veinte dispositivos y para ambas condiciones, de modo que cada dispositivo aporta 42 audios de entrenamiento (21 limpios y 21 con ruido), 8 de validación y 10 de prueba. La partición usa la semilla 42.

A.7.2 Verificación de consistencia por toma

Cada toma, identificada por su condición y nombre de archivo, existe en los veinte dispositivos. Como la partición se aplica de forma independiente por dispositivo y condición, el orden en que se listan los archivos podría hacer que una misma toma cayera en subconjuntos distintos según el dispositivo. Eso rompería el supuesto de fragmentos compartidos (Sección A.3) y permitiría que contenido casi idéntico apareciera en entrenamiento y en prueba.

Con lo cual, antes de continuar, el código recorre todas las tomas y comprueba que cada una esté asignada a un único subconjunto en todos los dispositivos. En la partición utilizada se verificaron 60 tomas compartidas (30 por condición) y todas resultaron consistentes.

A.7.3 Partición interna para el modelo definitivo

Del conjunto de entrenamiento se reservó el 15 % a nivel de audio, estratificado por dispositivo y condición (semilla 42). Esto da 714 audios de ajuste y 126 de control. La partición se hace antes de generar las ventanas, para que ventanas de un mismo audio no queden en ambos lados.

Tabla A9

Partición interna

Uso	Audios	Construcción de ventanas	Ventanas	Ventanas por audio
Ajuste	714	Fragmentos no vocalizados concatenados, 1 s sin solapamiento	29,971	42.0 ± 6.7
Control	126	Audio completo, 1 s sin solapamiento	9,568	75.9 ± 7.2

Esta partición es independiente del conjunto de validación y solo se usa para la detección temprana y la reducción adaptativa de la tasa de aprendizaje.

A.7.4 Tamaños efectivos de las muestras de evaluación

Las cifras de 200 audios de las secciones 2.1 y 2.2.2 son muestras de evaluación y no tamaños de conjunto. Su construcción es la siguiente:

- **Elegibilidad.** Solo entran audios de al menos 3 s (tres ventanas de análisis), para poder alojar un empalme con margen en ambos lados.
- **Igualación de duración.** Todos los audios del conjunto se recortan a la duración del más corto, de modo que la duración no sirva como pista de detección.
- **Auténticos.** Se muestrean 100 audios sin reemplazo del conjunto elegible.
- **Empalmados.** Se generan 100 empalmes entre dispositivos distintos. El corte debe quedar al menos 1.25 s (una ventana más un desplazamiento) de ambos extremos. **Nivel de ventana.** Se genera un empalme por cada par ordenado de dispositivos. Los conteos resultantes se muestran en la Tabla A.10.

Tabla A10

Muestras efectivas por conjunto

Conjunto	Audios en el conjunto	Duración común de recorte (s)	Auténticos usados	Empalmados usados
Validación (calibración)	160	69.54	100	100
Prueba	200	65.75	100	100
Dispositivos no vistos	504	14.40	100	100

Tabla A11

Pares de ventanas consecutivas por conjunto (evaluación a nivel de ventana)

Conjunto	Pares genuinos	Pares impostores	Proporción genuino:impostor
Validación (calibración)	164,853	1,454	113.4:1
Prueba	169,640	1,420	119.5:1
Prueba, solo limpias	144,068	1,520	94.8:1
Prueba, solo ruido	131,647	1,365	96.4:1
Dispositivos no vistos	77,694	533	145.8:1
Empalmes con IA	24,658	785	31.4:1

La construcción de los pares no depende de la métrica de distancia. Los conjuntos de solo limpias y solo ruido no suman el conjunto de prueba, porque el número de empalmes no

depende del tamaño del conjunto y la mayoría de los pares genuinos provienen de los tramos de los audios empalmados alejados del corte.

Los pares genuinos provienen de todos los audios auténticos de cada conjunto, sin recorte de duración, y de los tramos de los audios empalmados alejados del corte. Los pares impostores provienen de un empalme por cada par ordenado de dispositivos, de modo que cada empalme aporta pocos pares impostores: aquellos en los que el corte cae dentro del intervalo abarcado por las dos ventanas. Los pares genuinos son mucho más numerosos, y los impostores representan entre el 0.7 % y el 1.0 % de los pares en los conjuntos de empalmes sintéticos. Se excluyen los pares ambiguos, es decir, aquellos en los que la fracción de contenido de la fuente B que cambia entre las dos ventanas es mayor que 0 pero menor que 0.10. En el conjunto de empalmes con IA el etiquetado no usa esa fracción: un par es impostor si cruza un borde de la inserción, y genuino si ambas ventanas quedan al menos 0.5 s lejos del segmento insertado; los demás pares se descartan.

El EER es la métrica de evaluación definida en el plan del proyecto, y se reporta tanto sobre todos los pares como con submuestreo balanceado de los genuinos, con tantos pares genuinos como impostores en cada repetición. Al ser una tasa calculada por clase, el EER no depende de la proporción entre genuinos e impostores, y los resultados lo confirman: en las doce combinaciones de conjunto y métrica, el EER balanceado difiere del calculado con todos los pares en menos de 0.25 puntos porcentuales. El desbalance, que es consecuencia del escenario simulado (cada audio manipulado contiene un único corte, de modo que solo los pocos pares que lo rodean son impostores), no sesga la métrica elegida.

En los empalmes con IA, el resultado depende del nivel de análisis. Este conjunto constituye un escenario exigente: un tramo de habla del audio original se sustituye por un segmento de IA que dice el mismo texto con la voz clonada del propio hablante (XTTS v2), con fundido cruzado y ajuste de amplitud y de ruido de fondo al contexto, de modo que no cambian ni el hablante, ni el contenido, ni el dispositivo de captura. Además, el modelo se entrenó para discriminar dispositivos y no artefactos de síntesis. A nivel de ventana, el EER da cerca de 48 %. A nivel de audio, la puntuación de distancia máxima logra separar los 162 audios con reemplazo de 200 audios auténticos con un EER de 20.7 % (euclidiana), 21.0 % (Manhattan) y 21.6 % (SNR), con intervalos de confianza del 95 % de aproximadamente 17 % a 25 % (Mahalanobis: 29.3 %).

Sin embargo, la localización tiene un error medio de unos 19 s. Es decir, el máximo de distancia no coincide con el punto de empalme. Los audios base se tomaron de la base completa, antes de la partición, por lo que incluyen grabaciones que el modelo vio durante el

entrenamiento, mientras que los auténticos provienen sólo del conjunto de prueba. Además, difieren los hablantes y el contenido, y la duración es comparable (mediana de 81.7 s en los audios con reemplazo y 77.6 s en los auténticos). Con el modelo de síntesis utilizado, el resultado es consistente con que su huella no es equiparable a la de un cambio de micrófono (pero la verificación de esta hipótesis no corresponde a este trabajo).

Como trabajo futuro queda evaluar el sistema bajo más condiciones: más empalmes por par de dispositivos para aumentar el número de impostores independientes, y otros corpus y manipulaciones.

Tabla A12

Evaluación a nivel de ventana: todos los pares frente a submuestreo balanceado (distancia euclidiana)

Conjunto	Pares genuinos	Pares impostores	τ ventana	FAR (%)	FRR (%)	EER, todos los pares (%)	EER balanceado (%), media ± d.e.
Prueba	169 640	1 420	0.4264	20.49	18.56	19.44	19.44 ± 0.55
Prueba, solo limpia	144 068	1 520	0.4264	21.25	29.17	24.80	24.75 ± 0.53
Prueba, solo ruido	131 647	1 365	0.4264	26.96	7.79	16.04	16.02 ± 0.53
Dispositivos no vistos	77 694	533	0.4264	100.00	0.00	11.10	11.33 ± 0.64
Empalmes con IA	24 658	785	0.4264	56.82	40.55	48.24	48.31 ± 0.66

El submuestreo toma, en cada una de las 1000 repeticiones, tantos pares genuinos como impostores hay en el conjunto, sin reemplazo. Los pares impostores se usan completos.