ANEXO F. Curvas DET y distribuciones de puntuación a nivel de audio

F.1 Propósito. Este anexo respalda la sección 2.6.1. Presenta, para cada conjunto y para las cuatro métricas de distancia, la distribución de las puntuaciones de audio (distancia máxima entre ventanas consecutivas) y la curva DET.

F.2 Cómo leer las figuras. Cada figura tiene dos filas y cuatro columnas (euclidiana, Manhattan, Mahalanobis y SNR).

- *Fila superior:* histograma de puntuaciones de audios auténticos (azul) y empalmados (rojo), con densidad normalizada. La línea negra discontinua es el umbral congelado en validación (sección 2.6.3), no uno ajustado sobre el conjunto mostrado.
- *Fila inferior:* curva DET (FAR frente a FRR). El punto rojo es el EER con el umbral propio (ideal). El desempeño operativo es el obtenido con el umbral congelado (Tabla 4).

Las escalas de las métricas no son comparables, por lo que cada columna tiene su propio eje y umbral.

F.3 Conjunto de prueba (dispositivos vistos)

Figura F1

Histogramas de puntuación y curvas DET a nivel de audio, conjunto de prueba (100 auténticos, 100 empalmados)

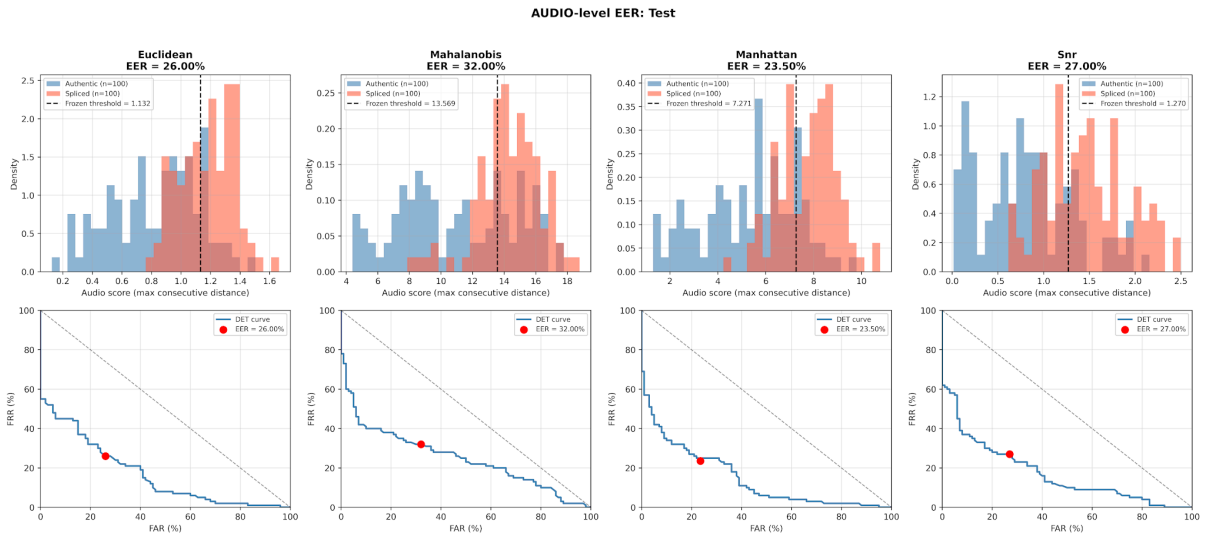


Tabla F1

EER con umbral propio y umbrales a nivel de audio, prueba.

Métrica	EER (%)	Umbral congelado	Umbral propio
Euclidiana	26.0	1.1323	1.0523

Manhattan	23.5	7.2711	6.8697
Mahalanobis	32.0	13.5693	13.5855
SNR	27.0	1.2700	1.1452

Las curvas de euclidiana, Manhattan y SNR son similares y Mahalanobis queda más alejada de la esquina inferior izquierda. En euclidiana, Manhattan y SNR el umbral congelado es algo mayor que el propio, por lo que deja pasar más empalmes (FAR de 34–41 %), mientras que en Mahalanobis ambos coinciden (13.57 frente a 13.59). Con el umbral congelado lo superan el 59–69 % de los empalmados y el 18–32 % de los auténticos.

F.4 Dispositivos no vistos

Figura F2

Histogramas de puntuación y curvas DET a nivel de audio, dispositivos no vistos (100 auténticos, 100 empalmados)

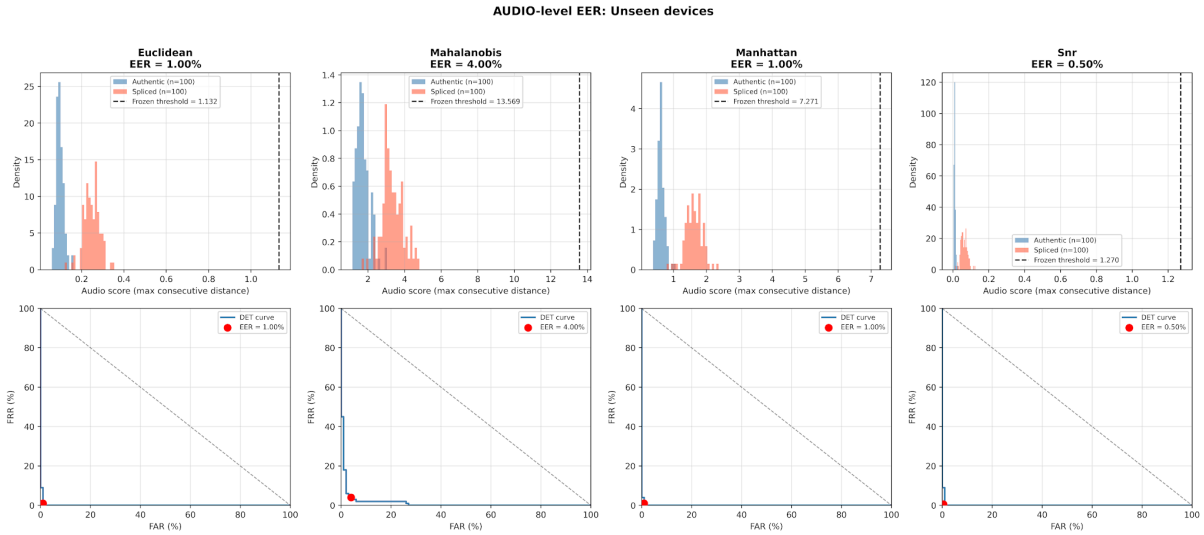


Tabla F2

EER con umbral propio y umbrales a nivel de audio, dispositivos no vistos.

Métrica	EER (%)	Umbral congelado	Umbral propio
Euclidiana	1.0	1.1323	0.1516
Manhattan	1.0	7.2711	0.9292
Mahalanobis	4.0	13.5693	2.3579
SNR	0.5	1.2700	0.0248

Aquí se ve directamente por qué no se emiten alarmas. Con distancia euclidiana, el máximo de los audios auténticos es 0.160 y el de los empalmados 0.354, frente a un umbral congelado de 1.132. Los umbrales propios (óptimos a posteriori) son entre 6 y 50 veces menores que los congelados. Por tanto, la curva DET muestra separación, pero el umbral depende del dominio.

F.5 Empalmes con voz sintetizada por IA

Figura F3

Histogramas de puntuación y curvas DET a nivel de audio, empalmes con IA (200 auténticos, 162 empalmados)

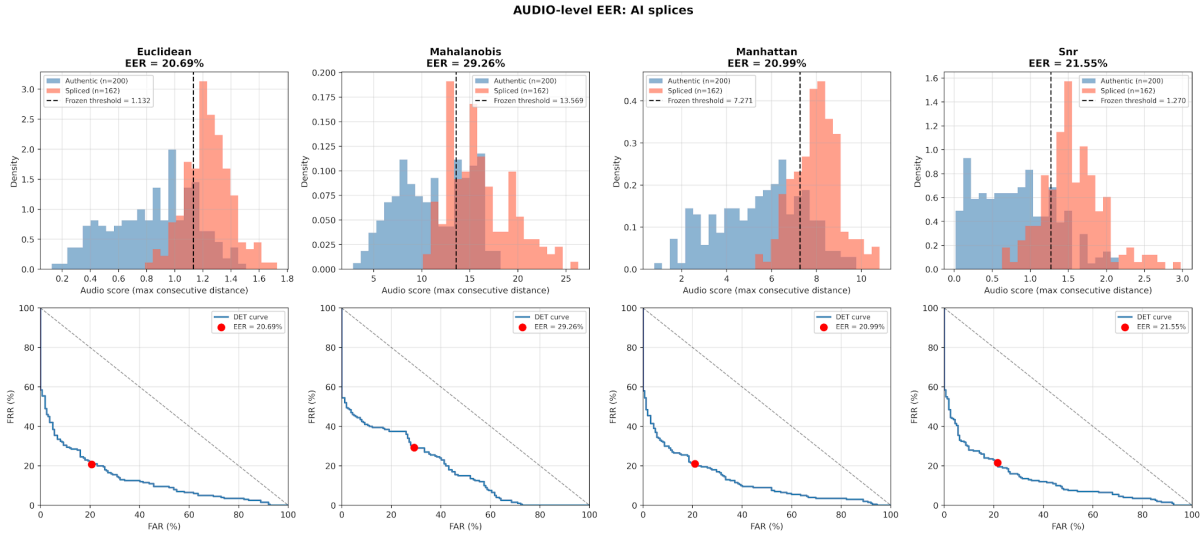


Tabla F3

EER con umbral propio y umbrales a nivel de audio, empalmes con IA.

Métrica	EER (%)	Umbral congelado	Umbral propio
Euclidiana	20.7	1.1323	1.1142
Manhattan	21.0	7.2711	7.2168
Mahalanobis	29.3	13.5693	13.9377
SNR	21.6	1.2700	1.2546

El umbral congelado es casi igual al propio, y supera el 75–78 % de los empalmados y el 20–34.5 % de los auténticos. Las curvas muestran separación a nivel de audio.

F.6 Nota sobre la muestra. Las curvas se estiman con 100 audios por clase (162 empalmados en IA), por lo que son escalonadas y sensibles a pocas muestras. Los intervalos bootstrap del EER están en el Anexo H.

F.7 Comparación adicional de distancias generadas con pérdidas tripletas y CosFace

Comportamiento en dispositivos no vistos. Para ver el efecto de la pérdida fuera de dominio, se evaluó con los mismos audios de MOBIPHONE un modelo entrenado con tripletas hard y uno entrenado con CosFace (distancia euclidiana)..

Sus resultados se pueden observar en las Figuras F4 y F5, donde se puede observar que con tripletas las distancias estan entre 0.0001 y 0.0006 con un umbral congelado en 0.0005, es decir que, el modelo con tripletas, no separó bien esos dispositivos. Sin embargo en el caso con CosFace, de la Figura F5, si se observa una buena separación además de valores de distancias entre 0.1 aproximadamente y 0.4 con un umbral en 1.1323, es decir que con CosFace si se logra transferir lo aprendido con POLIPHONE a dispositivos no vistos (MOBIPHONE).

Figura F4

Distribución de puntuaciones de audio en dispositivos no vistos frente al umbral congelado en validación con pérdida de tripletas (distancia euclidiana), entrenado con segmentos no vocalizados y ruido.

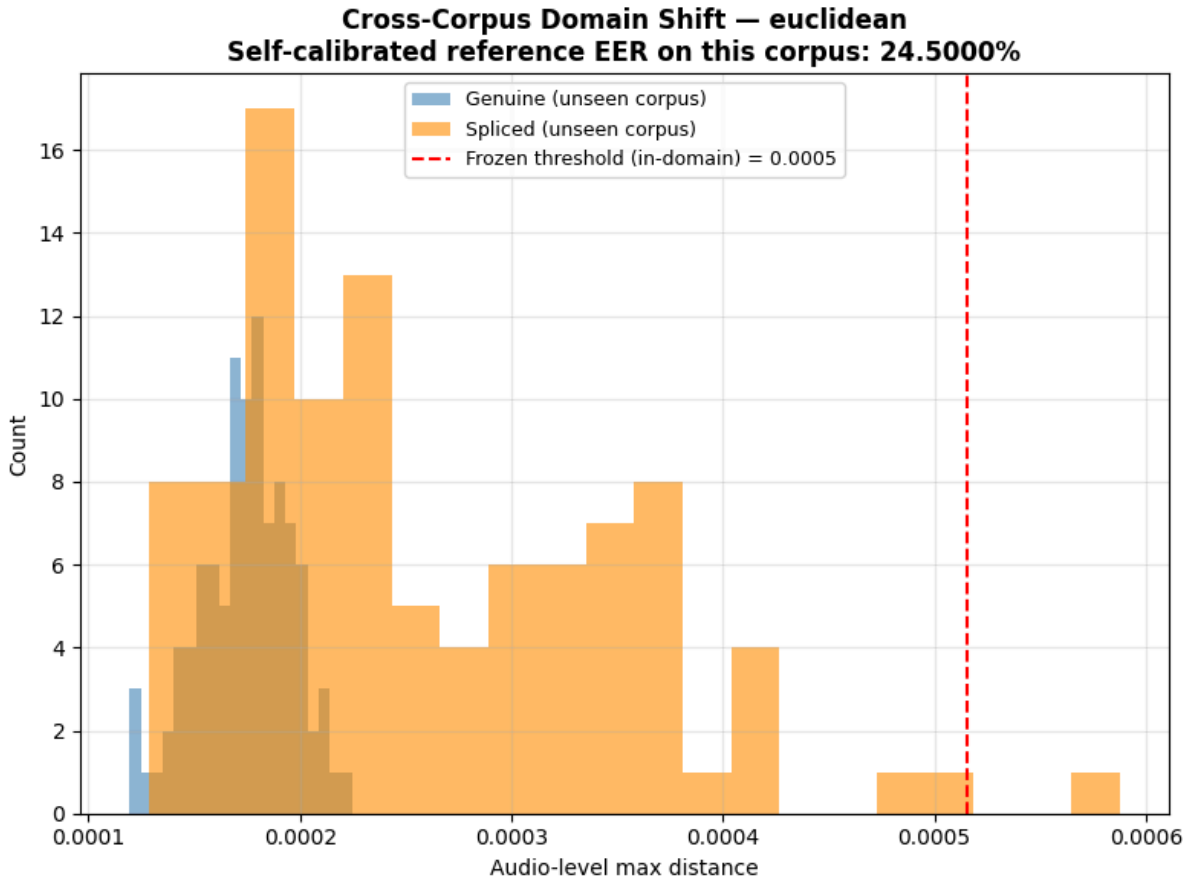
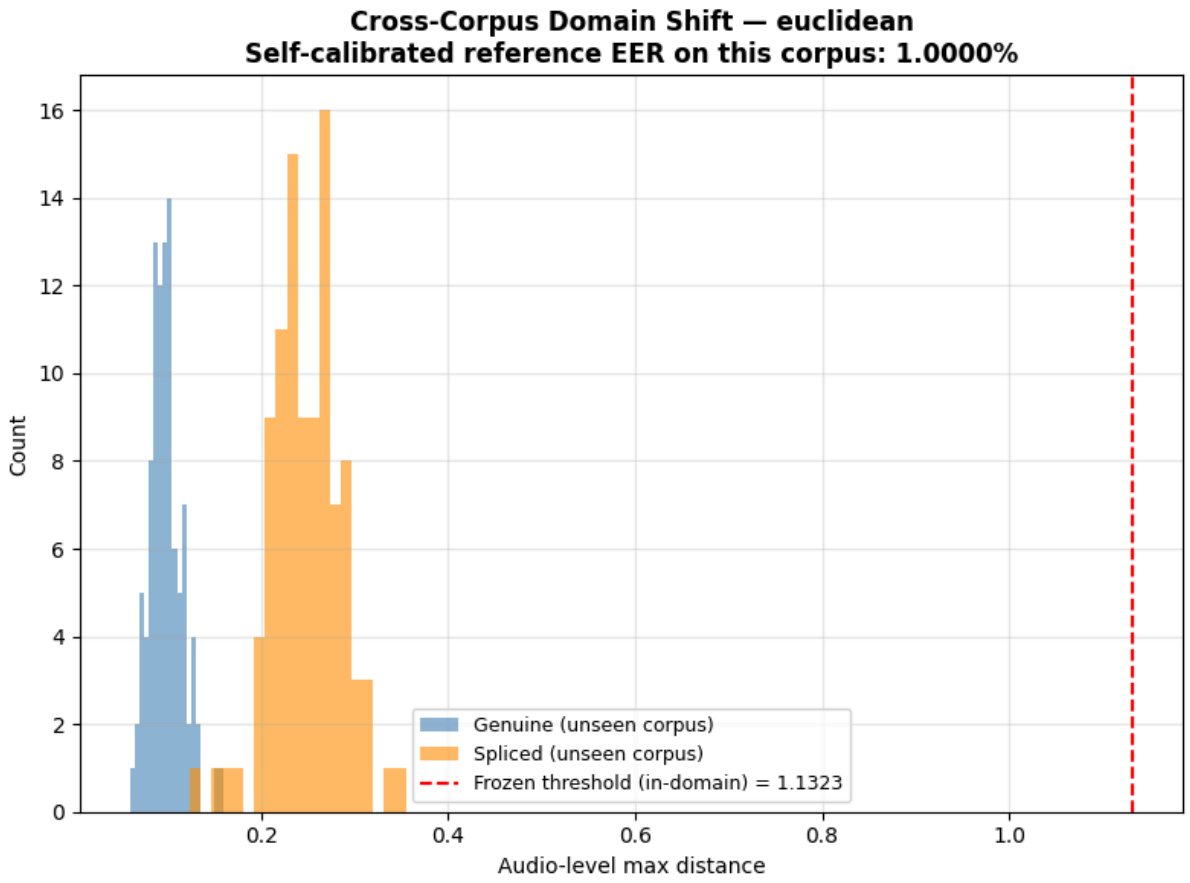


Figura F5

Evaluación de en dispositivos no vistos, CosFace con la versión final y entrando con audios no vocalizados más ruido.


Cross-Corpus Domain Shift — euclidean
Self-calibrated reference EER on this corpus: 1.0000%
Count
Audio-level max distance
Genuine (unseen corpus)
Spliced (unseen corpus)
Frozen threshold (in-domain) = 1.1323
0
2
4
6
8
10
12
14
16
0.2
0.4
0.6
0.8
1.0